

Combinação de Modelos Preditivos

Como combinar as previsões dos diferentes modelos?

A combinação pode ocorrer principalmente de duas formas: através de métodos baseados na decisão final (votação) ou métodos que utilizam informações mais detalhadas sobre a preferência do modelo (seriação).

Métodos de Votação (Fusão de Classificadores)

Estes métodos usam a saída final ("hard label") de cada modelo para tomar uma decisão conjunta.

- **Votação Simples (Majoritária):** Cada modelo base emite um "voto" para a classe que considera correta, e a classe que receber a maioria absoluta dos votos é escolhida como a predição final do *ensemble*. É o método mais intuitivo, garantindo uma decisão rápida e democrática entre modelos diversos.
- **Votação Ponderada:** Semelhante à votação simples, mas os votos têm pesos diferentes, geralmente atribuídos com base na confiança ou na precisão histórica de cada modelo. Assim, a decisão de um modelo altamente preciso tem mais impacto no resultado final do que a de um modelo menos confiável.

Métodos de Seriação (Ranking)

Nesta abordagem, a fusão não considera apenas uma escolha final, mas uma lista ordenada de preferências.

- **Fusão baseada em Seriação:** Em vez de emitir um único voto, cada classificador fornece um *ranking* completo ou um vetor de pontuações contínuas (probabilidades) para todas as classes possíveis. A combinação final agrega esses *rankings* — por meio de médias, somas ou regras mais complexas — para determinar a classe com a maior pontuação global, aproveitando informações ricas que seriam perdidas em uma votação simples.

Métodos Estáticos vs. Métodos Dinâmicos

A forma como combinamos os modelos também pode ser fixa ou adaptar-se a cada nova situação.

- **Métodos Estáticos:** A regra ou os pesos de combinação são definidos de forma global durante o treinamento e permanecem constantes para todas as novas instâncias que o sistema precisa classificar.
- **Métodos Dinâmicos:** A combinação ajusta-se localmente, considerando as características específicas do exemplo atual que está sendo avaliado para decidir qual modelo tem maior probabilidade de acertar aquela instância em particular.

Exemplos de Métodos Dinâmicos

MAI - Model Applicability Induction (Indução de Aplicabilidade de Modelo)

O MAI atua como um sistema de meta-aprendizado que analisa o espaço de características para descobrir ativamente "qual modelo usar para cada tipo de dado". Ele treina um classificador adicional focado exclusivamente em prever se um modelo base específico será capaz de classificar corretamente uma nova instância não vista.

SCANN - Análise de Correspondência Seguida por um Vizinho Mais Próximo

O SCANN é um método sofisticado que primeiro aplica uma Análise de Correspondência para transformar e projetar os dados em um novo espaço vetorial otimizado. Em seguida, ele utiliza o algoritmo do Vizinho Mais Próximo (KNN) nesse novo espaço estruturado para explorar a similaridade local e realizar a classificação final com base na vizinhança.

A Sinergia: Combinação MAI + SCANN

A integração dessas duas técnicas cria um sistema dinâmico extremamente poderoso, operando em duas etapas complementares:

- **Passo 1 (A Estruturação):** O SCANN é utilizado para reorganizar o espaço de dados, projetando-os em uma estrutura onde instâncias semelhantes são agrupadas mais claramente. A etapa do *nearest neighbor* é vital aqui para mapear e identificar essas regiões geográficas locais de similaridade dentro do novo espaço de dados.
- **Passo 2 (A Decisão Dinâmica):** Em vez do SCANN ditar a classe final, a estrutura espacial criada por ele é entregue ao MAI. O MAI então analisa essa "geografia" de dados para aprender, região por região, qual dos modelos de base apresenta o melhor desempenho histórico ali, roteando a decisão final dinamicamente para o modelo mais apto para aquele local específico.